

05

Módulo 05 - Técnicas de avaliação de modelos de IA

Fundamentos de Inteligência Artificial (IA)

Resumo do Módulo

- ♦ A Importância de Avaliar a Performance de um Modelo.
- ♦ Métricas Comuns em Aprendizagem Supervisionada: Precisão, Revocação, AUC-ROC, Entre Outras.
- ♦ Técnicas de Validação Cruzada.
- ♦ Overfitting e Underfitting: Diagnóstico e Soluções.
- ♦ Lab

♦ Lab 05 - Técnicas de avaliação de modelos de IA

• 5.1 – escola de detetives

=====

🔍 ESCOLA DE DETETIVES 🔍

=====

👋 Olá, detetive!

📺 NOTÍCIA: Houve um concurso de talentos de animais!

😬 O júri usou uma REGRA SECRETA para escolher os vencedores.

🎯 A TUA MISSÃO:

- 1 Investigar os concorrentes do passado
- 2 Descobrir a regra secreta
- 3 Prever quem vai ganhar no PRÓXIMO concurso

🏆 Vamos ver se és bom detetive!

Para criar um modelo de machine learning válido

é essencial avaliar e quantificar a sua **performance** em termos de:

1. **Precisão** - Proporção de previsões corretas entre as identificadas como positivas
2. **Fiabilidade** - Consistência dos resultados do modelo em diferentes condições



Mas?
Precisão
ou
Acurácia?

↑
exatidão

Precisão vs Acurácia

Precisão (Precision) - mede a proporção de verdadeiros positivos entre todas as previsões positivas **50%**

Acurácia (Accuracy) - mede a proporção de previsões corretas em relação ao total de previsões **91%**

Valores Reais

Valores Previstos

		Positivo (1)	Negativo (0)
Positivo (1)	TP	01 (Verdadeiro Positivo)	01 (Falso Positivo)
	FN	08 (Falso Negativo)	90 (Verdadeiro Negativo)
Negativo (0)			

$$\text{Precisão} = (\text{TP}) / (\text{TP} + \text{FP})$$

$$\text{Precisão} = (1) / (1 + 1)$$

$$\text{Precisão} = 1 / 2$$

$$\text{Precisão} = \mathbf{0.50}$$

$$\text{Acurácia} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{FN} + \text{TN})$$

$$\text{Acurácia} = (1 + 90) / (1 + 90 + 1 + 8)$$

$$\text{Acurácia} = 91 / 100$$

$$\text{Acurácia} = \mathbf{0.91}$$

Matriz de confusão

Precisão vs Revocação

Precisão (Precision) - mede a proporção de verdadeiros positivos entre todas as previsões positivas **50%**

Revocação (Recall) - mede a proporção de verdadeiros positivos entre todos os casos realmente positivos **11%**

Valores Reais

Valores Previstos

	Positivo (1)	Negativo (0)
Positivo (1)	TP 01 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
Negativo (0)	FN 08 (Falso Negativo)	TN 90 (Verdadeiro Negativo)

$$\text{Precisão} = (\text{TP}) / (\text{TP} + \text{FP})$$

$$\text{Precisão} = (1) / (1 + 1)$$

$$\text{Precisão} = 1 / 2$$

$$\text{Precisão} = \mathbf{0.50}$$

$$\text{Revocação} = (\text{TP}) / (\text{TP} + \text{FN})$$


$$\text{Revocação} = (1) / (1 + 8)$$

$$\text{Revocação} = 1 / 9$$

$$\text{Revocação} = \mathbf{0.11}$$


Matriz de confusão

Valores que dependem do limiar da decisão (neste caso classificação)



Valores Reais


	Positivo (1)	Negativo (0)
Valores Previstos Positivo (1)	TP 07 (Verdadeiro Positivo)	FP 01 (Falso Positivo)
Valores Previstos Negativo (0)	FN 04 (Falso Negativo)	TN 18 (Verdadeiro Negativo)



Valores Reais

	Positivo (1)	Negativo (0)
Valores Previstos Positivo (1)	TP 09 (Verdadeiro Positivo)	FP 03 (Falso Positivo)
Valores Previstos Negativo (0)	FN 02 (Falso Negativo)	TN 16 (Verdadeiro Negativo)

Medida F1 (F1-score)



Acurácia (Accuracy) - mede a proporção de previsões corretas em relação ao total de previsões $(TP + TN) / (TP + FP + FN + TN)$

Precisão (Precision) - mede a proporção de verdadeiros positivos entre todas as previsões positivas $(TP) / (TP + FP)$

Revocação (Recall) - mede a proporção de verdadeiros positivos entre todos os casos realmente positivos $(TP) / (TP + FN)$


F1-score (ou F-score e F-measure) é a média harmónica entre precisão e revocação, e fornece uma medida de equilíbrio entre ambas

F1-Score máximo é 1.0, indicando Precisão e Recall perfeitos


valor mínimo possível é 0.0

- ♦ A **AUC-ROC** é uma métrica que avalia a performance de um modelo de classificação.
 - O gráfico **ROC** (Receiver Operating Characteristic) mostra a **relação entre o True Positive Rate (TPR) e o False Positive Rate (FPR)** para diferentes limiares de classificação
 - **AUC** (Area Under the Curve) mede a área sob essa curva.
 - AUC de 1 indica um modelo perfeito
 - 0,5 significa um modelo aleatório.

A linha tracejada representa um modelo de classificação aleatório, e **quanto mais a curva ROC se afastar dessa linha, melhor será o desempenho do modelo.**




Métricas para Regressão Linear



$$MAE = \frac{1}{n} \sum |y - \hat{y}|$$

O **Erro Médio Absoluto (MAE)** diz, em média, o quanto longe as previsões estão dos valores corretos.



$$MSE = \frac{1}{n} \sum (y - \hat{y})^2$$

O **Erro Quadrático Médio (MSE)** faz o mesmo, mas dá mais importância a erros grandes.

Modelos de Machine Learning que vamos “tentar” ver nos próximos módulos

◆ Supervisionada (Supervised):

- Regressão (Regression): **Linear Simples • Linear Múltipla • Polinomial • Lasso • Ridge**
- Classificação (Classification): **Regressão Logística • KNN • SVM • Kernel SVM • Naïve Bayes**
- Séries Temporais (Time Series): **ARIMA • SARIMA • LSTM • Prophet • Suavização Exponencial**
- Métodos de Conjunto (Ensemble Methods): **Árvore de Decisão • Random Forest • XGBoost • CatBoost**
- Aprendizagem Profunda (Deep Learning): **Redes Neurais Artificiais • Convolucionais • Recorrentes • Transformers + Atenção**

◆ Não Supervisionada (Unsupervised):

- Clustering (Agrupamento): **K-means • Hierárquico • GMM**
- Redução de Dimensionalidade (Dimensionality Reduction): **PCA • Kernel PCA • LDA**

◆ Reforço (Reinforcement):

- Algoritmos de Reforço (Reinforcement Algorithms): **Limite de Confiança Superior • Amostragem de Thompson • Q-Learning • Deep Q-Learning • PPO**
- Algoritmos Genéticos (Genetic Algorithms): **Algoritmo Genético Clássico • NSGA-II • Algoritmos Meméticos**

ALTO!

... como é que eu vou saber tanta tralha?

Não vou! (esta informação **demora anos a aprender e dominar**)!

A não ser que use LLMS (Large Language Models)!

Entra o prompt do CEO:

Dá-me um briefing diário conciso, como o que um CEO receberia. Restringe-te ao que da aprendizagem temporal **ARIMA** que devo conhecer. Para cada secção, inclui fontes credíveis. Mantém o texto abaixo das 200 palavras e foca-te no que realmente importa e porquê.

(...)

Cria um hands on lab python claro que me permita dominar o 80/20 do tema como um developer que não programa à muito tempo e não uses Jupiter notebook.

◆ Supervisionada (Supervised):

◆ Regressão (Regression)

- **Erro Médio Absoluto (MAE):** Mede a magnitude média dos erros em relação aos valores reais.
- **Erro Quadrático Médio (MSE):** Penaliza erros maiores, elevando-os ao quadrado.
- **Raiz do Erro Quadrático Médio (RMSE):** Interpretação mais intuitiva do erro médio, pois mantém a unidade original.
- **R^2 (Coeficiente de Determinação):** Mede a proporção da variabilidade explicada pelo modelo.

◆ Classificação (Classification)

- **Acurácia (Accuracy):** Proporção de previsões corretas no total.
- **Precisão (Precision):** Proporção de verdadeiros positivos entre os positivos previstos.
- **Recall:** Proporção de verdadeiros positivos entre os casos reais positivos.
- **F1-Score:** Média harmónica entre **precisão** e **recall**, útil para dados não balanceados.
- **ROC AUC (Area Under the Curve):** Mede a habilidade do modelo em classificar corretamente as classes positivas e negativas.
- **Matriz de Confusão:** Ajuda a identificar verdadeiros e falsos positivos/negativos

Métricas para as categorias de Machine Learning

◆ Supervisionada (Supervised):

◆ Séries Temporais (Time Series):

- **Erro Médio Absoluto Percentual (MAPE):** Percentagem média do erro em relação aos valores reais.
- **Erro Quadrático Médio (MSE):** Penaliza erros maiores, sendo útil para identificar desvios significativos.
- **AIC (Akaike Information Criterion) e BIC (Bayesian Information Criterion):** Usados para comparar modelos e penalizar complexidade.
- **Coeficiente de Determinação (R^2):** Mede o quão bem os valores previstos se ajustam aos valores reais.

◆ Métodos de Conjunto (Ensemble Methods):

- **Acurácia, F1-Score, ROC AUC:** Métricas gerais para modelos de classificação.
- **Importância das Variáveis (Feature Importance):** Mede a contribuição relativa de cada variável no modelo.

◆ Aprendizagem Profunda (Deep Learning):

- **Cross-Entropy Loss:** Comum em problemas de classificação, com redes neurais.
- **MSE ou MAE:** Usado para regressão com redes neurais.
- **Acurácia, ROC AUC, F1-Score:** Podem ser usados para avaliar redes neurais em tarefas de classificação.

Métricas para as categorias de Machine Learning

◆ Não Supervisionada (Unsupervised):

◆ Clustering (Agrupamento):

- **Índice de Silhueta (Silhouette Score):** Mede o quão bem um ponto está agrupado, variando de -1 a 1 (quanto mais próximo de 1, melhor o agrupamento).
- **Coeficiente de Rand Ajustado (Adjusted Rand Index):** Mede a similaridade entre dois agrupamentos, considerando a aleatoriedade.
- **Inércia (K-means):** Soma das distâncias quadráticas dentro de cada cluster, usada como critério para minimizar a variabilidade intra-cluster.
- **V-Measure:** Avalia a homogeneidade e a completude dos clusters.

◆ Redução de Dimensionalidade (Dimensionality Reduction):

- **Explained Variance Ratio (PCA):** Percentagem da variância total capturada pelas componentes principais.
- **Distância de Reconstrução (Reconstruction Error):** Mede o quão bem os dados originais podem ser reconstruídos a partir das dimensões reduzidas.

Métricas para as categorias de Machine Learning

◆Reforço (Reinforcement):

◆Algoritmos de Reforço (Reinforcement Algorithms):

- **Recompensa Cumulativa:** Soma de todas as recompensas obtidas ao longo do tempo.
- **Taxa de Convergência:** Mede a rapidez com que o modelo converge para uma política ótima.
- **Eficácia da Política:** Mede o desempenho da política final em maximizar a recompensa a longo prazo.
- **Tempo de Exploração vs. Exploração (Exploration vs. Exploitation Trade-off):** Avalia o equilíbrio entre a exploração de novas ações e a exploração de ações conhecidas.

◆Algoritmos Genéticos (Genetic Algorithms):

- **Fitness Function:** Avalia a qualidade de uma solução candidata.
- **Número de Gerações:** Mede quantas gerações são necessárias para encontrar uma solução ótima.
- **Diversidade Genética:** Mantém a variabilidade das soluções ao longo do tempo.

Código Python

```
from sklearn.metrics import mean_absolute_error
y_true = [3, -0.5, 2, 7]
y_pred = [2.5, 0.0, 2, 8]
print(mean_absolute_error(y_true, y_pred))
```

```
from sklearn.metrics import mean_squared_error
y_true = [3, -0.5, 2, 7]
y_pred = [2.5, 0.0, 2, 8]
print(mean_squared_error(y_true, y_pred))
```

```
from sklearn.metrics import r2_score
y_true = [3, -0.5, 2, 7]
y_pred = [2.5, 0.0, 2, 8]
print(r2_score(y_true, y_pred))
```

```
from sklearn.metrics import mean_squared_error
import numpy as np
y_true = [3, -0.5, 2, 7]
y_pred = [2.5, 0.0, 2, 8]
print(np.sqrt(mean_squared_error(y_true, y_pred)))
```

```
from sklearn.metrics import accuracy_score
y_true = [0, 1, 1, 0]
y_pred = [0, 1, 0, 1]
print(accuracy_score(y_true, y_pred))
```

```
from sklearn.metrics import precision_score
y_true = [0, 1, 1, 0]
y_pred = [0, 1, 0, 1]
print(precision_score(y_true, y_pred))
```

```
from sklearn.metrics import recall_score
y_true = [0, 1, 1, 0]
y_pred = [0, 1, 0, 1]
print(recall_score(y_true, y_pred))
```



```
from sklearn.metrics import confusion_matrix
y_true = [0, 1, 1, 0]
y_pred = [0, 1, 0, 1]
print(confusion_matrix(y_true, y_pred))
```

```
from sklearn.metrics import f1_score
y_true = [0, 1, 1, 0]
y_pred = [0, 1, 0, 1]
print(f1_score(y_true, y_pred))
```



```
from sklearn.metrics import roc_auc_score
y_true = [0, 1, 1, 0]
y_pred = [0.1, 0.9, 0.8, 0.2]
print(roc_auc_score(y_true, y_pred))
```

Underfitting (Subajuste) e Overfitting (Sobreaajuste)

- ◆ **Underfitting:** O modelo é **demasiado simples** e **não captura os padrões relevantes**, resultando em baixo desempenho.



- ◆ **Overfitting:** O modelo ajusta-se **demasiado** aos dados de treino, tendo **mau desempenho** com novos dados.



- ◆ Lab 05 - Técnicas de avaliação de modelos de IA
 - 5.2 – Academia ML do Drone Coruja