Seminário - Entender e Enfrentar o Mundo dos Deepfakes

Academia AI Engineer

Resumo do Seminário

- Introdução aos Deepfakes
- Como os Deepfakes são criados
- Usos e aplicações dos Deepfakes
  - Aplicações positivas
  - Riscos e consequências
- Ferramentas de identificação e verificação de Deepfakes

Bom ou mau?


MEDIA REPORT
COMMUNICATION REVIEW
Deepfake
How to recognize disinformation created by AI?
deep fake
Fake or fact?

Natureza Humana?

...1865...



FALSO (FAKE)

Presidente **Abraham Lincoln** numa pose majestosa

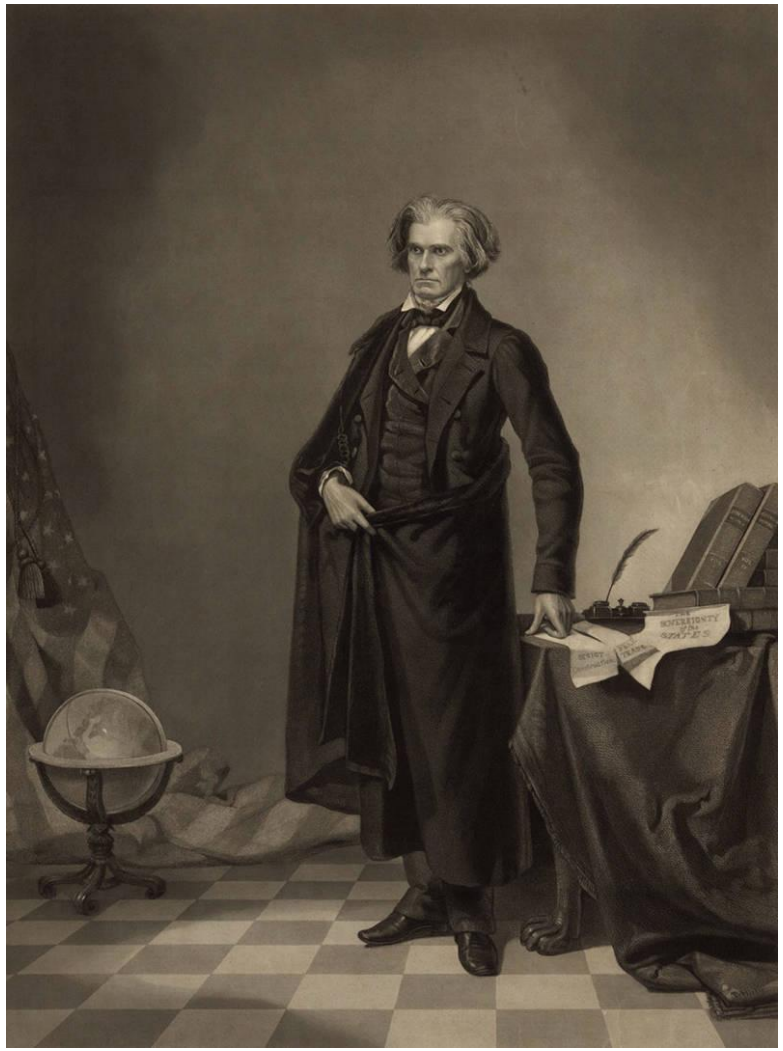


Imagem real

(Vice-Presidente **John C. Calhoun**)

Fake news?

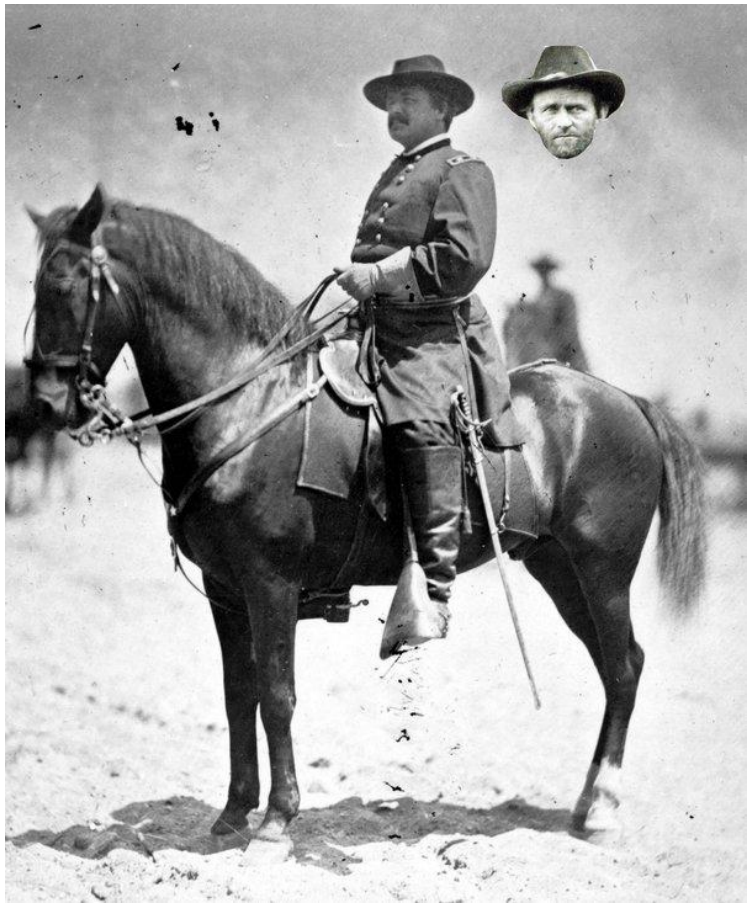
Falso!
O General Ulysses S. Grant **não estava** em City Point (no estado americano da Virgínia)

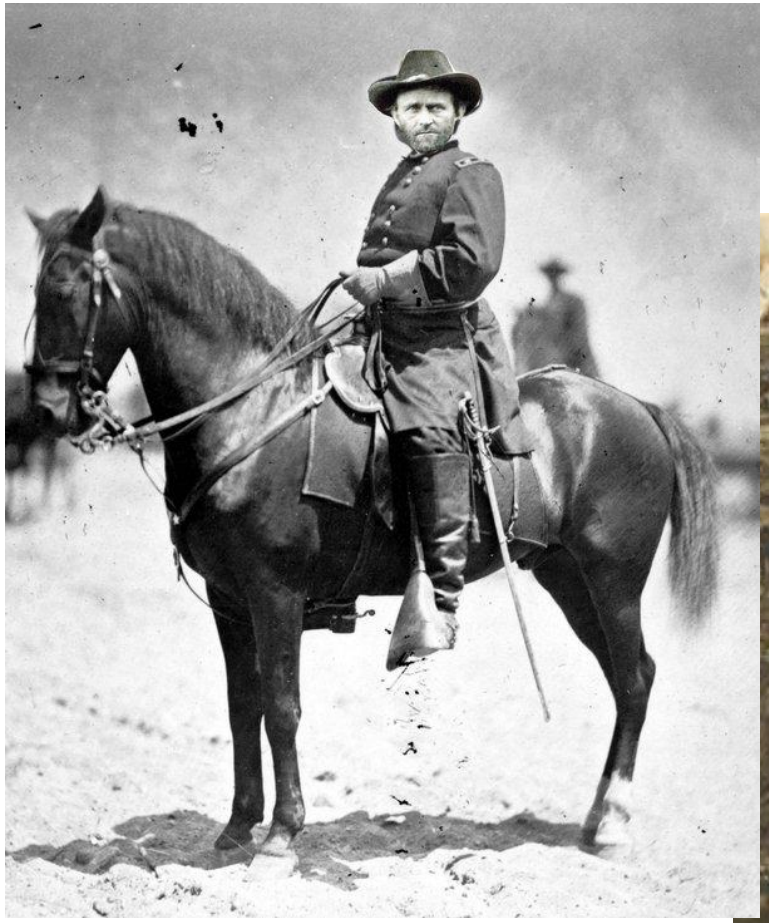


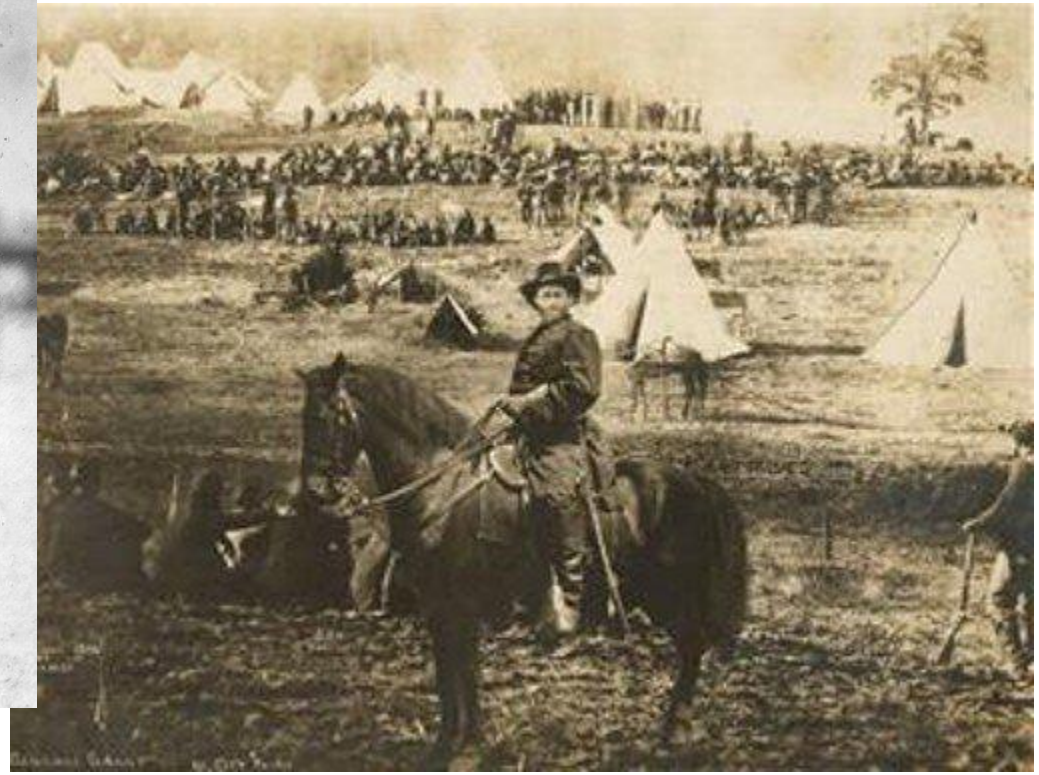
Composite Photo.
Aonde está a real?
Meta: **Fake social**!

Alexander McDowell McCook →Levin Corbin Handy → Ulysses S. Grant

Após a morte do 18º Presidente Americano Grant em 1896, em 1902 o fotografo **Levin Corbin Handy** tentou refazer a história.







Fake social?

O Castelo de São Jorge tem “apenas” 80 anos!





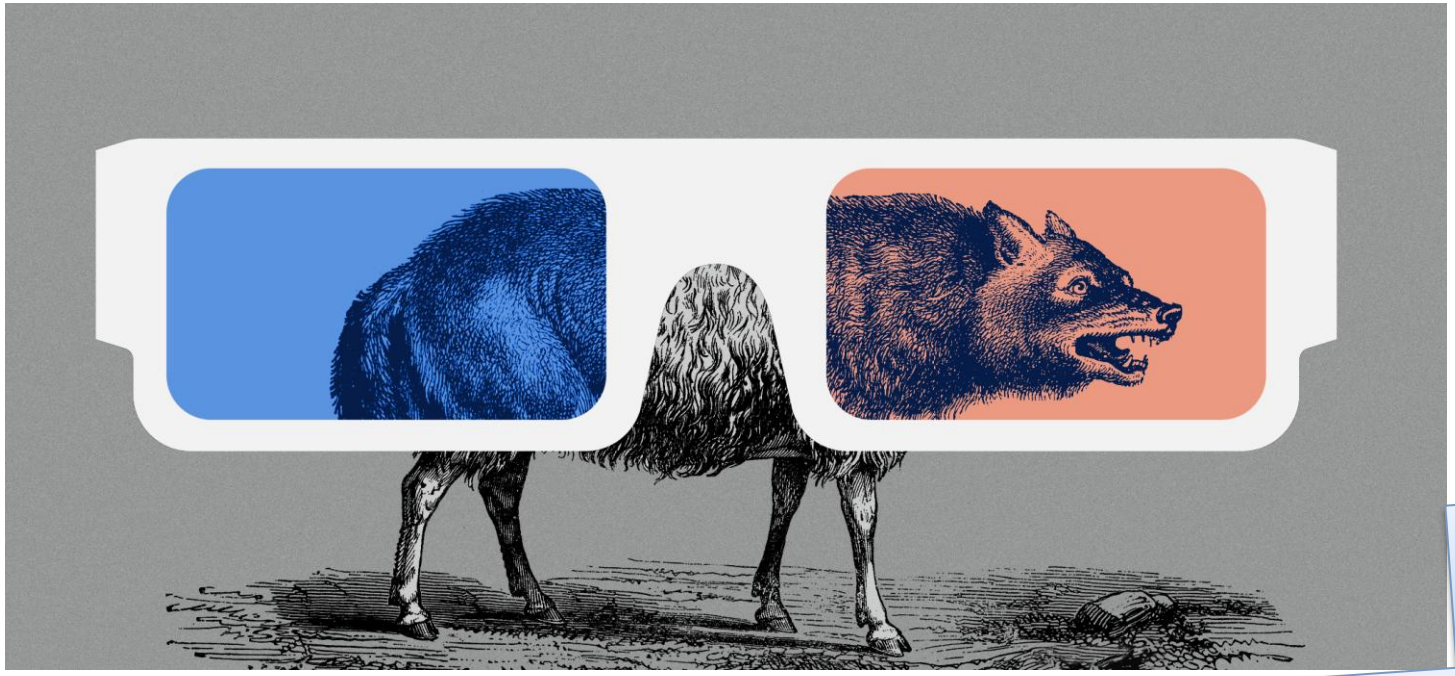
Foto: Eduardo Portugal [1939] | Arquivo Municipal de Lisboa

1. A partir do séc. XVI o rei e a corte abandonaram o Castelo.
2. A partir daí, o Castelo assumiu uma função militar que durou até ao final do século XIX.
3. Pelo meio, o terramoto de 1755 deixou em ruínas a zona do Castelo.
4. Entre 1938 e 1940, O Salazar reconstruiu o Castelo.

Deepfakes

deep learning + *fake* = Deepfake

(*falso*)



(normalmente são GANs)

(com uma grande componente autoregressiva)

DeepFakes vs Cheap Fakes (Report DS_Deepfakes_Cheap_FakesFinal.pdf)

Melhor Qualidade (Realismo)

Pior Qualidade (Percetível)

TECHNOLOGIES

- Recurrent Neural Network (RNN); Hidden Markov Models (HMM) and Long Short Term Memory Models (LTSM)
- Generative Adversarial Networks (GANs)
- Video Dialogue Replacement (VDR) model
- FakeApp / After Effects
- After Effects, Adobe Premiere Pro
- Sony Vegas Pro
- Free real-time filter applications
- Free speed alteration applications
- In-camera effects
- Relabeling/ Reuse of extant video

DEEPFAKES More expertise and technical resources required — Less expertise and fewer technical resources required **CHEAP FAKES**

TECHNIQUES

- Virtual performances *(page 35)*
- Virtual performances
- Voice synthesis *(page 38)*
- Face swapping *(page 35)*
- Lip-synching *(page 38)*
- Face swapping: Rotoscope
- Speeding and slowing *(page 30)*
- Face altering/ swapping
- Speeding and slowing
- Lookalikes *(page 27)*
- Recontextualizing *(page 28)*

EXAMPLES



Suwajanajorn et al. Face2Face: Synthesizing Obama



Posters and Howe's: Mark Zuckerberg

Deepfakes: Gal Gadot (not pictured because of image content)


Mario Klingemann: AI Art


Jordan Peele and BuzzFeed: Obama PSA



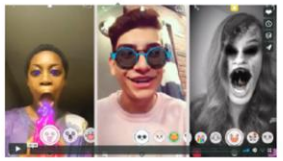
Paul Joseph Watson: Acosta Video


Belle Delphine: Hit or Miss Choreography

Rana Ayyub (not pictured because of image content)



Huw Parkinson: Uncivil War


SnapChat: Amsterdam Fashion Institute


Unknown: BBC NATO newscast

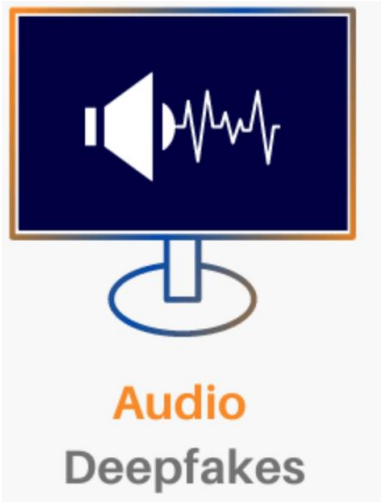
3 Tipos bases de Deepfakes

1



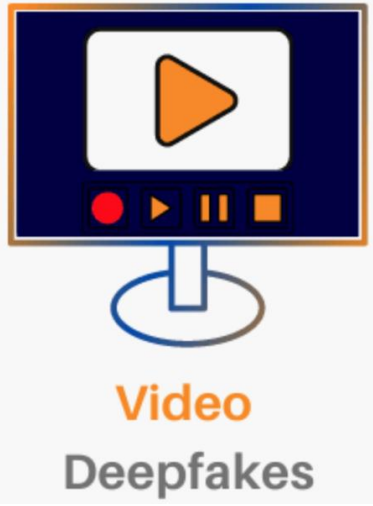
conteúdos textuais gerados por inteligência artificial que **imitam o estilo e o tom de comunicações reais**

2



áudios manipulados ou gerados por inteligência artificial que **reproduzem a voz e a entoação de uma pessoa**

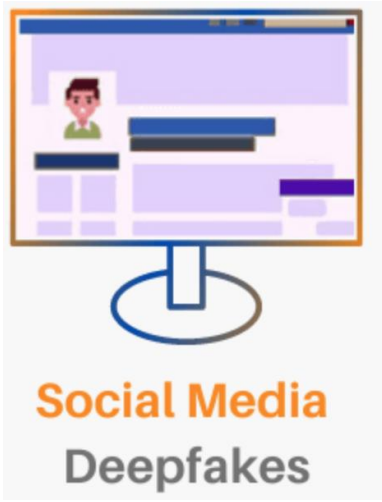
3



vídeos manipulados ou gerados por inteligência artificial que **substituem rostos, gestos e expressões**

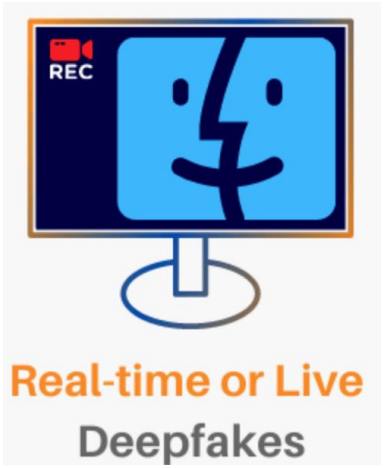
+2 Tipos de Deepfakes compostos

4



conteúdos falsos gerados por inteligência artificial que **procuram influenciar opiniões**

5



manipulações de vídeo ou áudio feitas em tempo real por inteligência artificial para criar uma presença fictícia do **rosto ou voz de uma pessoa durante transmissões ao vivo ou videoconferências**

DeepFakes – Textual Deepfakes

O mais fácil de fazer!

Prompt:*"Imagina que és um escritor a tentar replicar o estilo de José Saramago. Cria um texto de 100 palavras sobre a solidão, com frases longas, pontuação reduzida e ênfase em reflexões internas."*

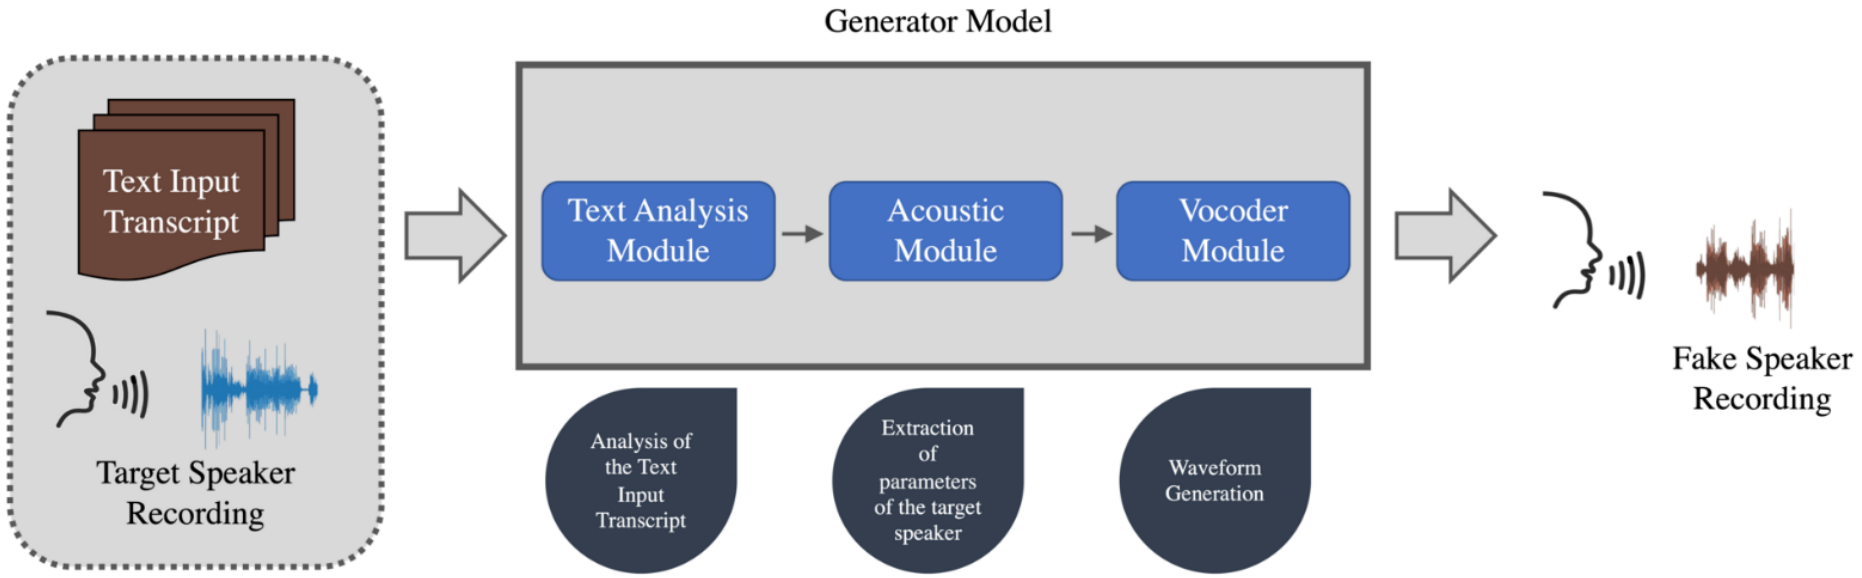
Oportunidades

+ Automação de Textos
+ Criação Literária
+ Tradução Personalizada

Ameaças

- Desinformação e Propaganda
- Fraude e Phishing
- Manipulação de Opiniões

DeepFakes – Audio Deepfakes



Oportunidades

+ Assistentes virtuais personalizados
+ Acelerar a produção de conteúdo
+ Preservar a voz da pessoa

Ameaças

- Falsificação de identidades e apropriação: Imitação convincente de qualquer pessoa
- Ataques biométricos e Vishing (Vishing é phishing que usa chamadas de voz)

Audio Deepfake

Experimentar

https://research.myshell.ai/open-voice

Lab

Ex 01: DeepFakes – Audio Deepfakes

O nosso exercicio é colocar a correr o:

https://github.com/SWivid/F5-TTS (ou https://github.com/resemble-ai/chatterbox)

https://huggingface.co/spaces/ResembleAI/Chatterbox-Multilingual-TTS

Links de outros Deepfakes Audio:

https://github.com/CorentinJ/Real-Time-Voice-Cloning ← o 1º a sério

https://github.com/abus-aikorea/voice-pro ← (um filho do 1º)

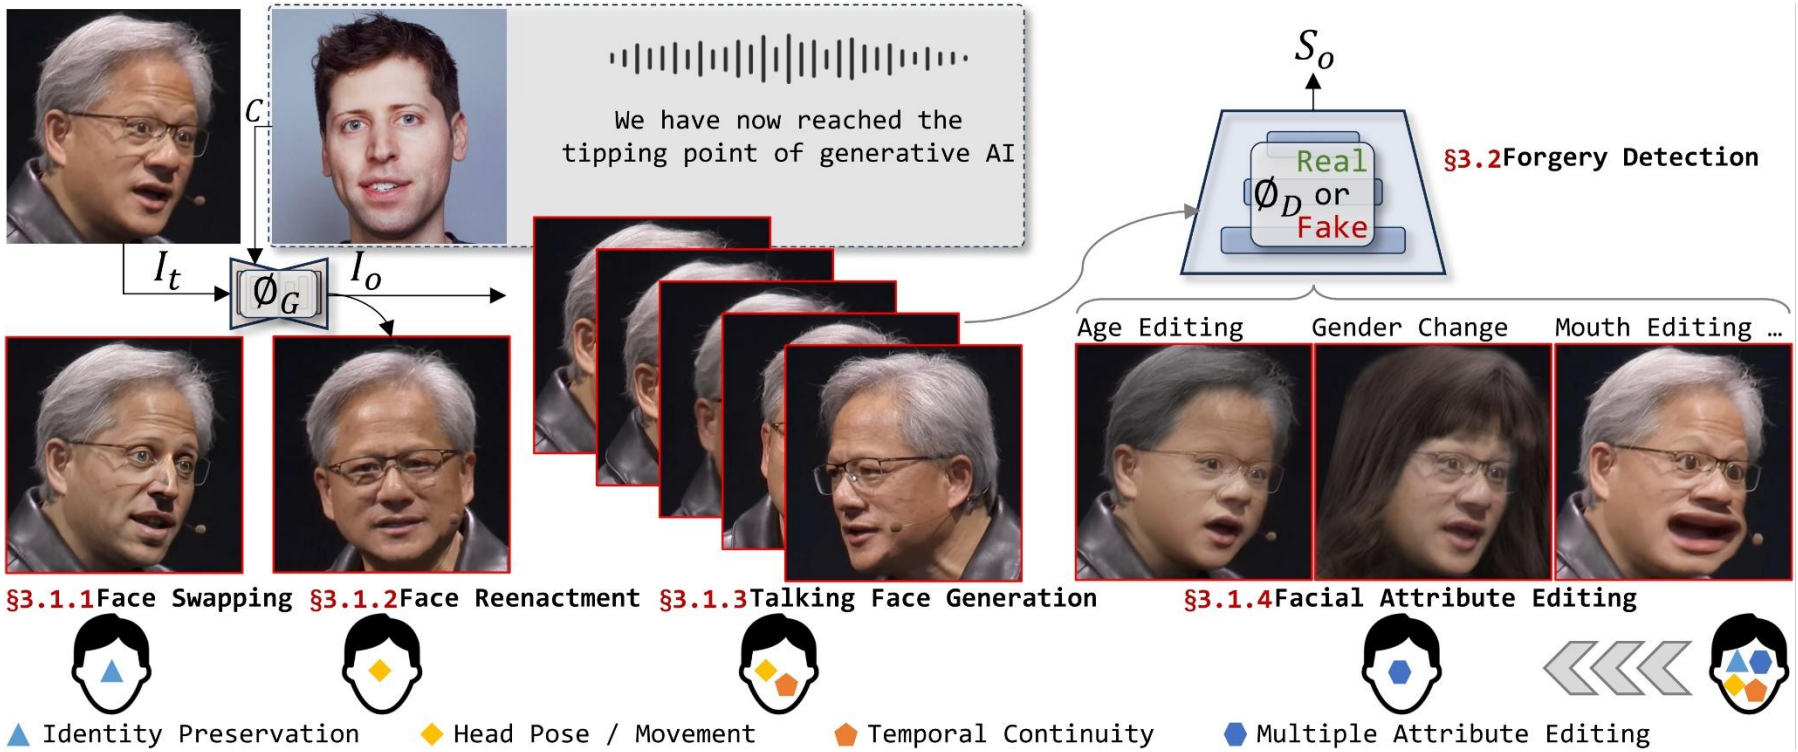
https://github.com/topics/voice-clone ← outros c/ codigo

https://elevenlabs.io/ ← pago

e deteção:

https://github.com/Guri10/Deepfake-Audio-Detection-with-XAI

DeepFakes – Video Deepfakes



Oportunidades

+ Assistentes virtuais personalizados
+ Acelerar a produção de conteúdo
+ Preservar a imagem/comportamento da pessoa

Ameaças

- Falsificação de identidades: Imitação convincente da pessoa

Video Deepfake



Lab

Ex 02: DeepFakes – Video Deepfakes

O nosso exercício é colocar a correr o:

https://github.com/facefusion/facefusion

Links de outros Deepfakes Video:

https://github.com/deepfakes/faceswap ← Uma alternativa

https://rundiffusion.com/facefusion-online ← O fusion online e pago

https://github.com/iperov/DeepFaceLab ← o 1º a sério

https://github.com/topics/deepfake ← outros c/ codigo

E deteção

https://scanner.deepware.ai/