02

Módulo 02 - Variational Autoencoders (VAEs)

Inteligência Artificial Generativa e Modelos de Linguagem de Grande Escala (LLMs)

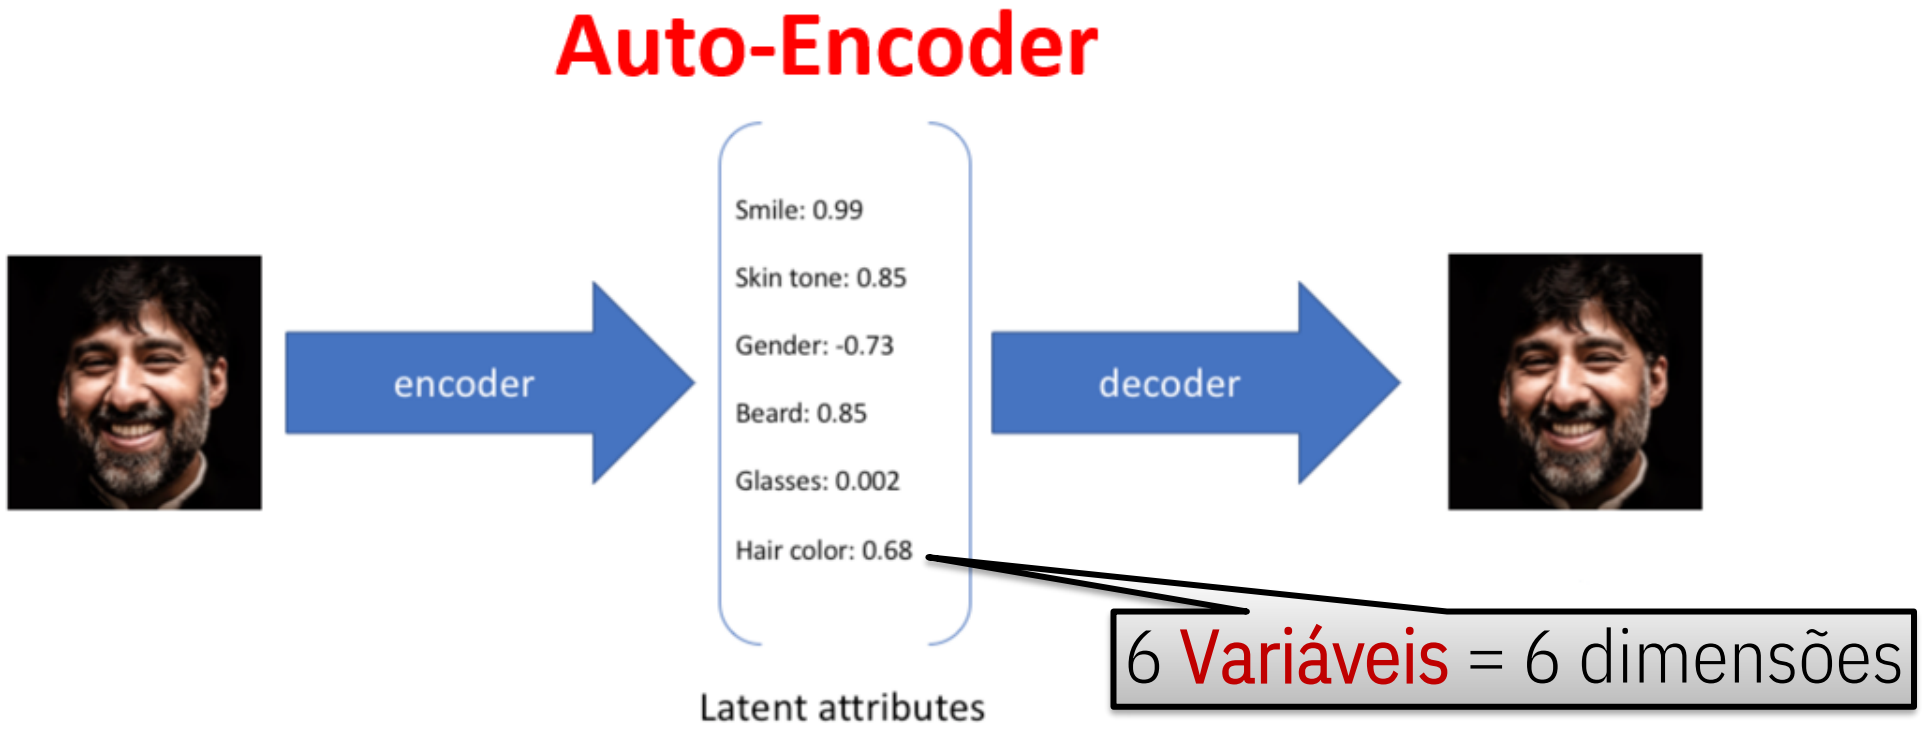
Resumo do Módulo

- Introdução aos autoencoders.
- Como funcionam os VAEs.
- Aprendizagem de representações.
- Aplicações práticas.
- Lab

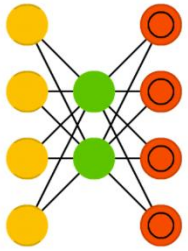
Introdução aos autoencoders.

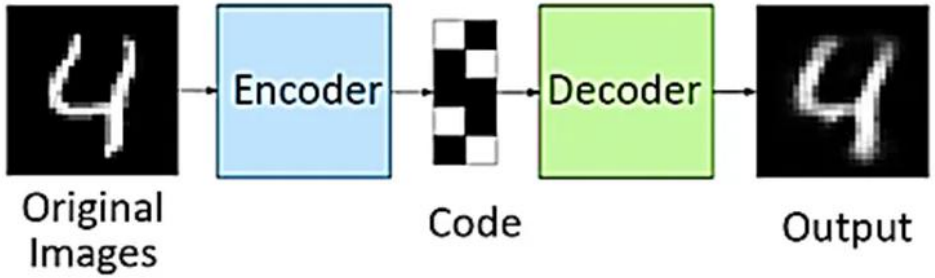
São redes neurais **que aprendem a** codificar (comprimir) e decodificar (reconstruir) dados.

Objetivo: Extrair uma representação interna (latente) compacta que retenha as informações principais.



Auto-encoder (AE)



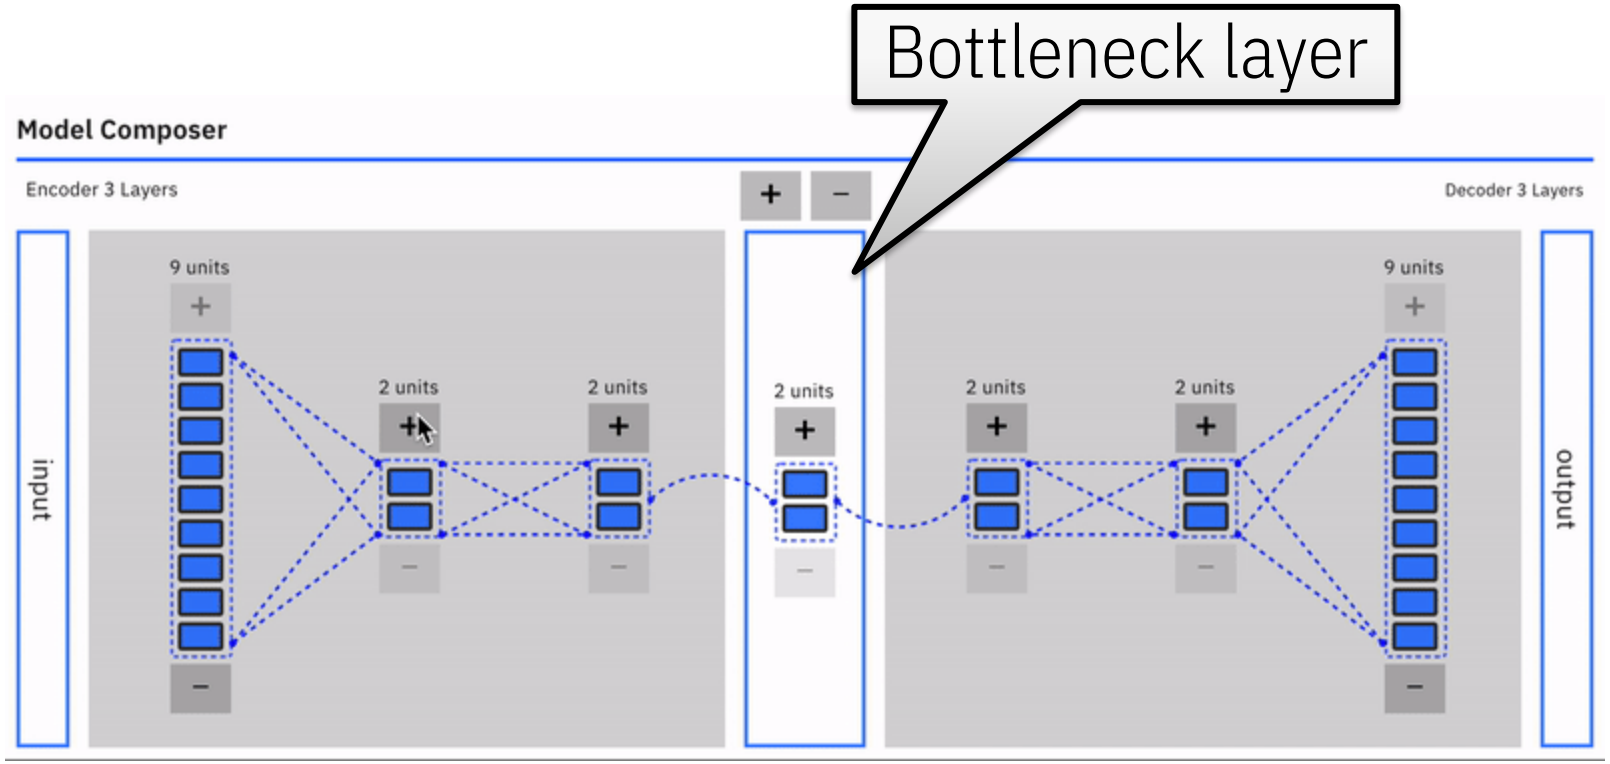


- Célula de entrada
- Célula de entrada retroalimentada
- Célula de entrada com ruído
- Célula escondida
- Célula escondida probabilística
- Célula escondida com disparo
- Célula cápsula
- Célula de saída
- Célula de saída igual à de entrada
- Célula recorrente
- Célula de memória
- Célula de memória com portão
- Kernel
- Convolução ou pool

- Projetados para reduzir a dimensionalidade da informação de entrada
- Camada escondida central tem menos neurónios que a camada de entrada
- Camada de saída replica a informação de entrada
- Durante o treino, aprendem a compactar a informação mantendo o suficiente para reconstrução
  1. Primeira metade da rede: encoder (comprime a informação)
  2. Segunda metade da rede: decoder (reconstrói a informação)

(Usos: compactação de dados para armazenamento/transmissão ou representação reduzida para uso por outras redes neurais especializadas)

Regras para dimensionar um Auto-encoder (AE)



1. **Camada de Entrada:** $I = D$ neurónios (onde D é o número de variáveis).
2. **Bottleneck:** $B \approx \alpha \times D$ (por exemplo, $\alpha \in [0.1, 0.5]$ consoante a compressão desejada).
3. **Camadas Ocultas (Encoder e Decoder)**: decrescem/ascendem em passos intermédios, por exemplo:

$$D \rightarrow \frac{D+B}{2} \rightarrow B \rightarrow \frac{D+B}{2} \rightarrow D.$$

Use regularização (dropout, L1, L2) e "early stopping" para evitar sobreajuste.

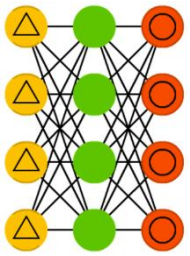
Espaço Latente dos Auto-encoders (AEs)

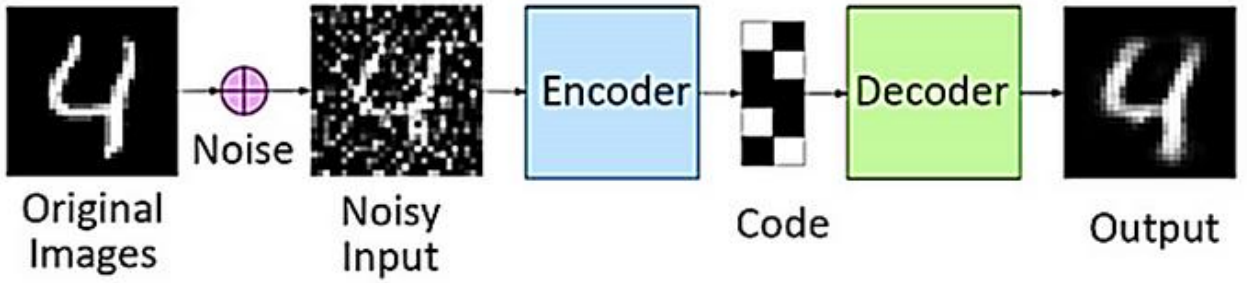
Os AEs aprendem um espaço de vetores discreto, permitindo recriar as amostras treinadas.

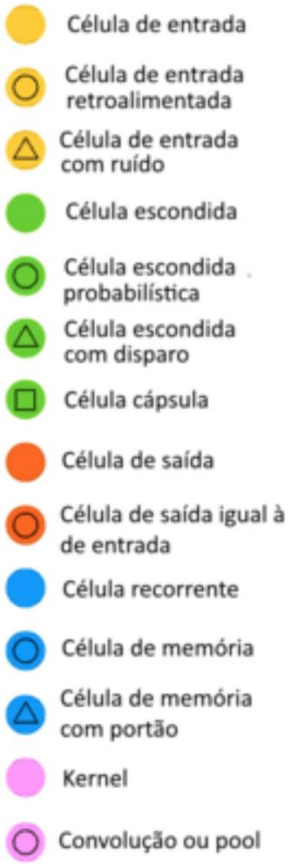


https://douglasduhaime.com/posts/visualizing-latent-spaces.html

Denoising auto-encoder (DAE)



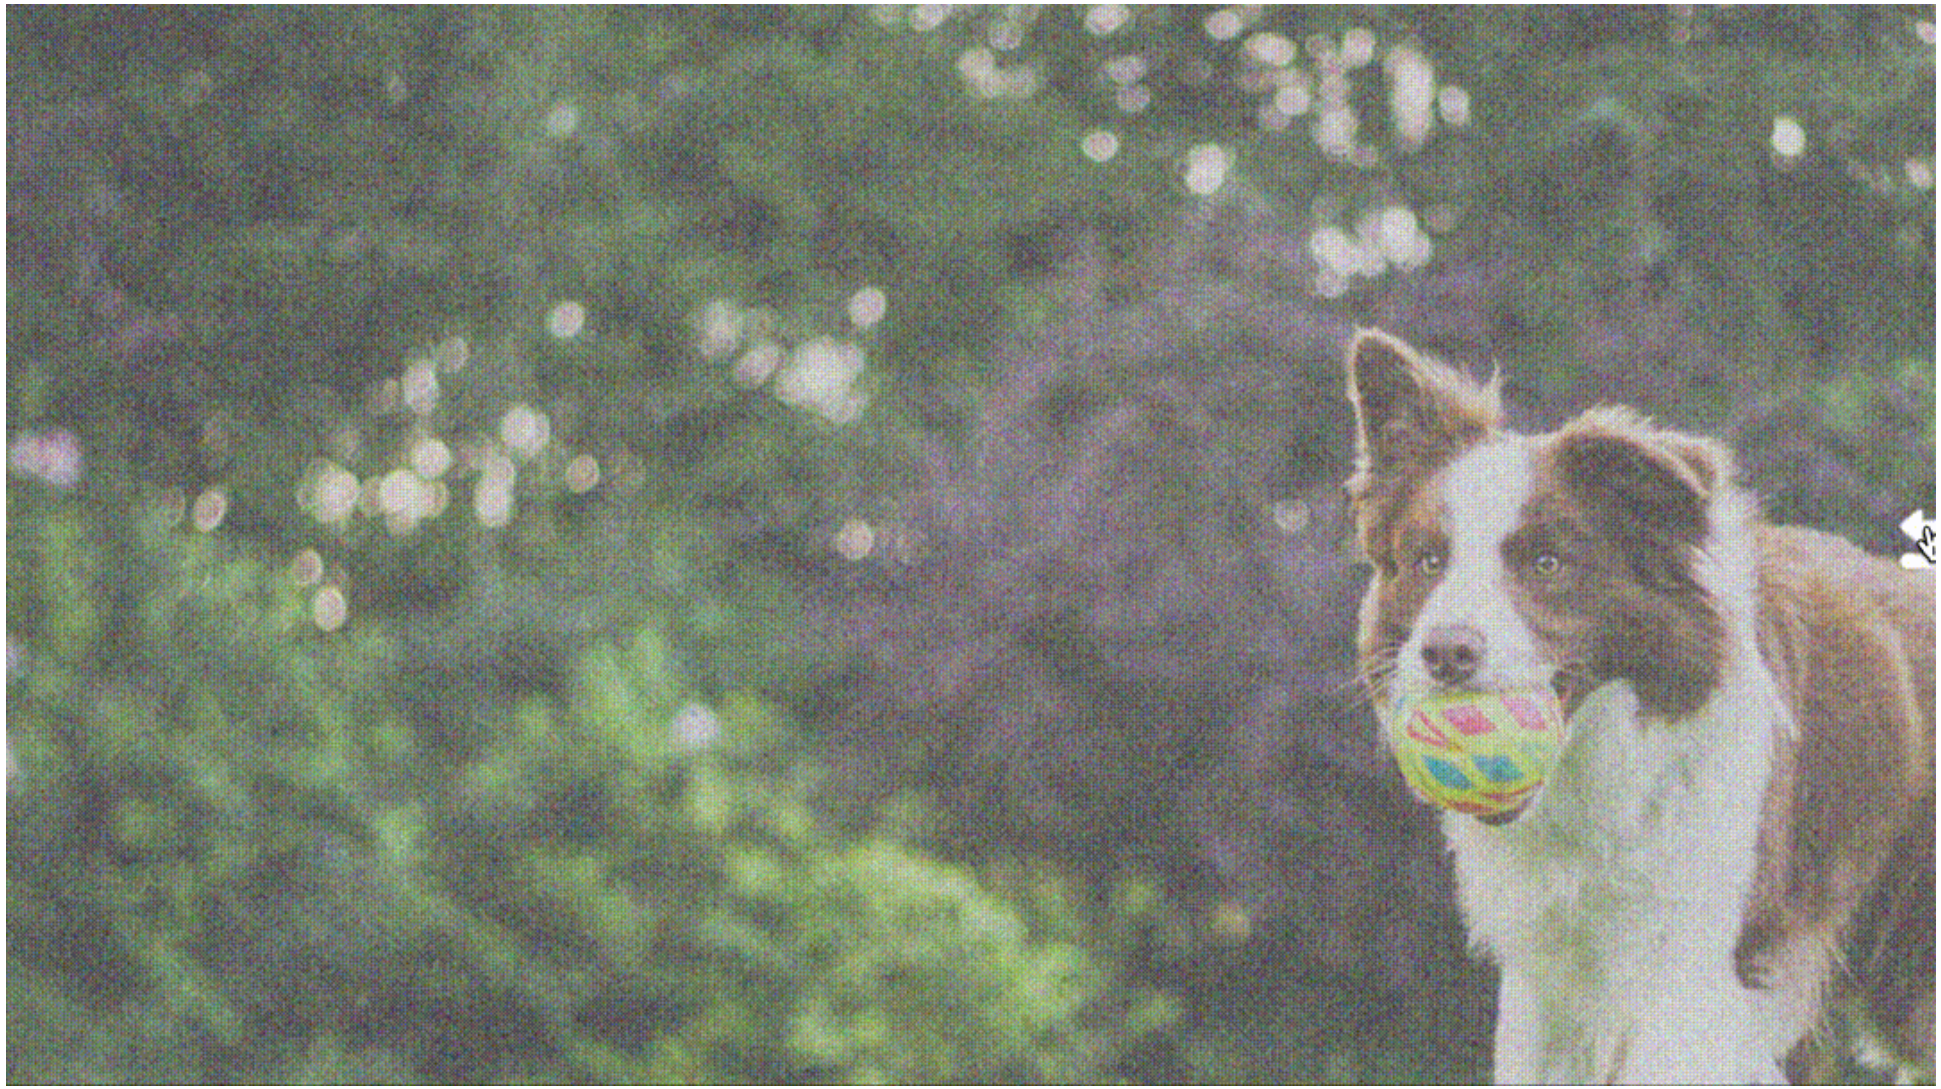




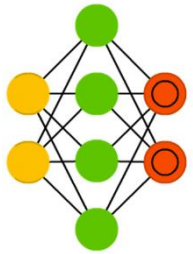
- Dados de entrada são os dados originais com ruído adicionado
- A rede aprende a capturar informações mais amplas, ignorando o ruído

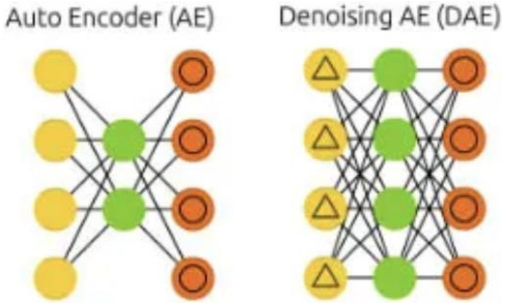
(Aplicação principal: limpar dados com ruído, como aumentar a resolução de vídeos antigos)

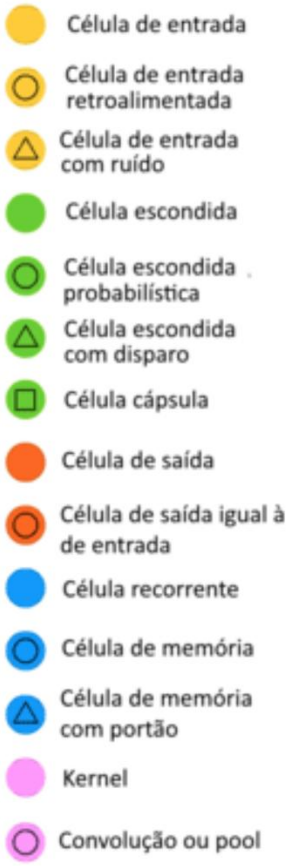
Antes e depois de um Denoising auto-encoder (DAE)



Sparse auto-encoder (SAE) - auto-encoder esparso

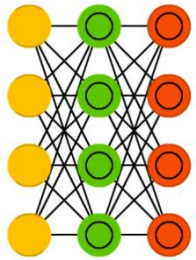


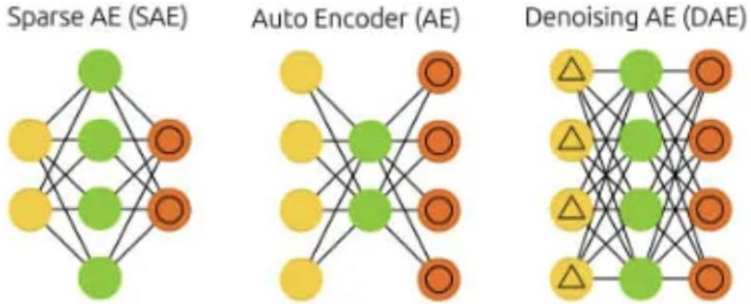


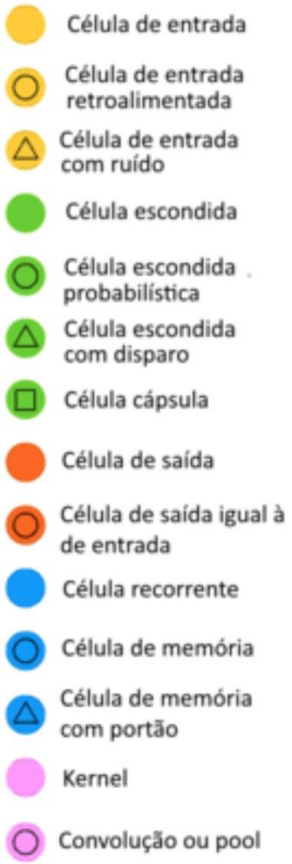


- Faz o oposto que o auto-encoder tradicional
- Representa os dados originais em um espaço dimensional maior
- Objetivo: descobrir novos features menores ocultos nas inter-relações dos dados originais
- Focado em capturar informações escondidas no dataset

Variational auto-encoder (VAE) - auto-encoder variacional



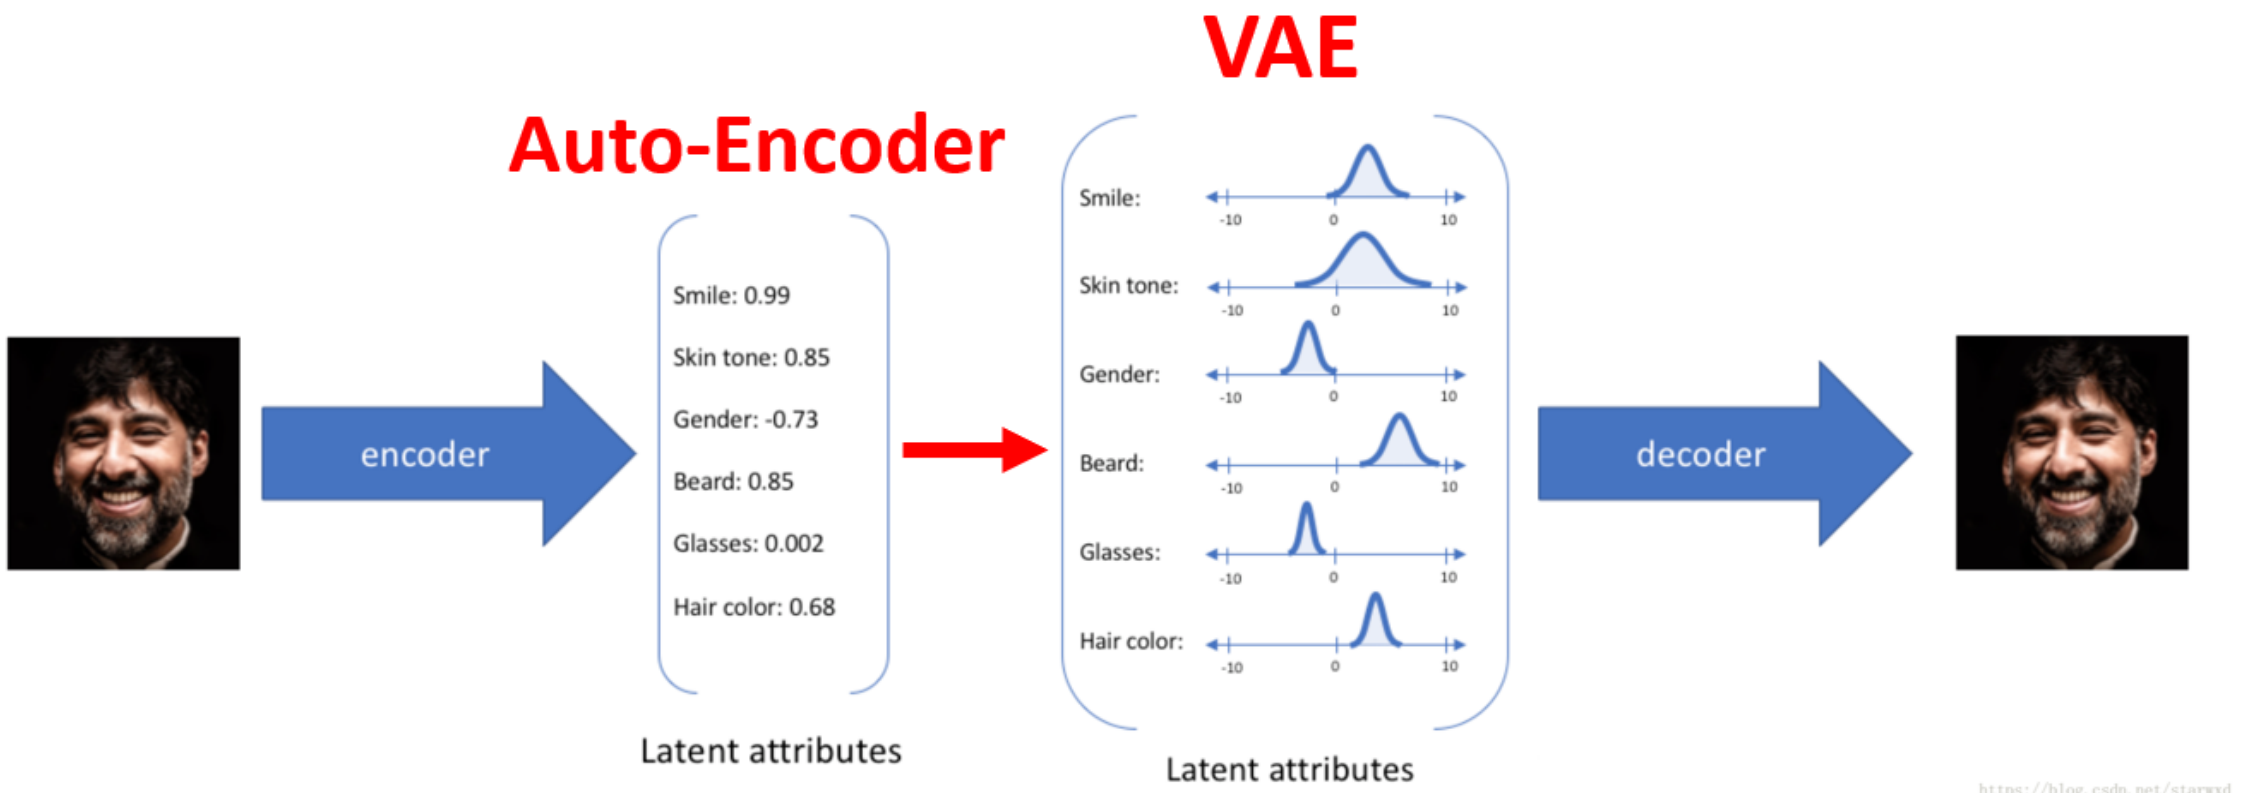




- Similar ao auto-encoder, mas representa os dados como distribuições probabilísticas
- Tarefa principal: reconstruir dados originais a partir dessas distribuições
- Representa a natureza das variáveis de entrada como probabilidades
- Usado para treino e inferência em problemas de natureza probabilística

Como funcionam os VAEs.

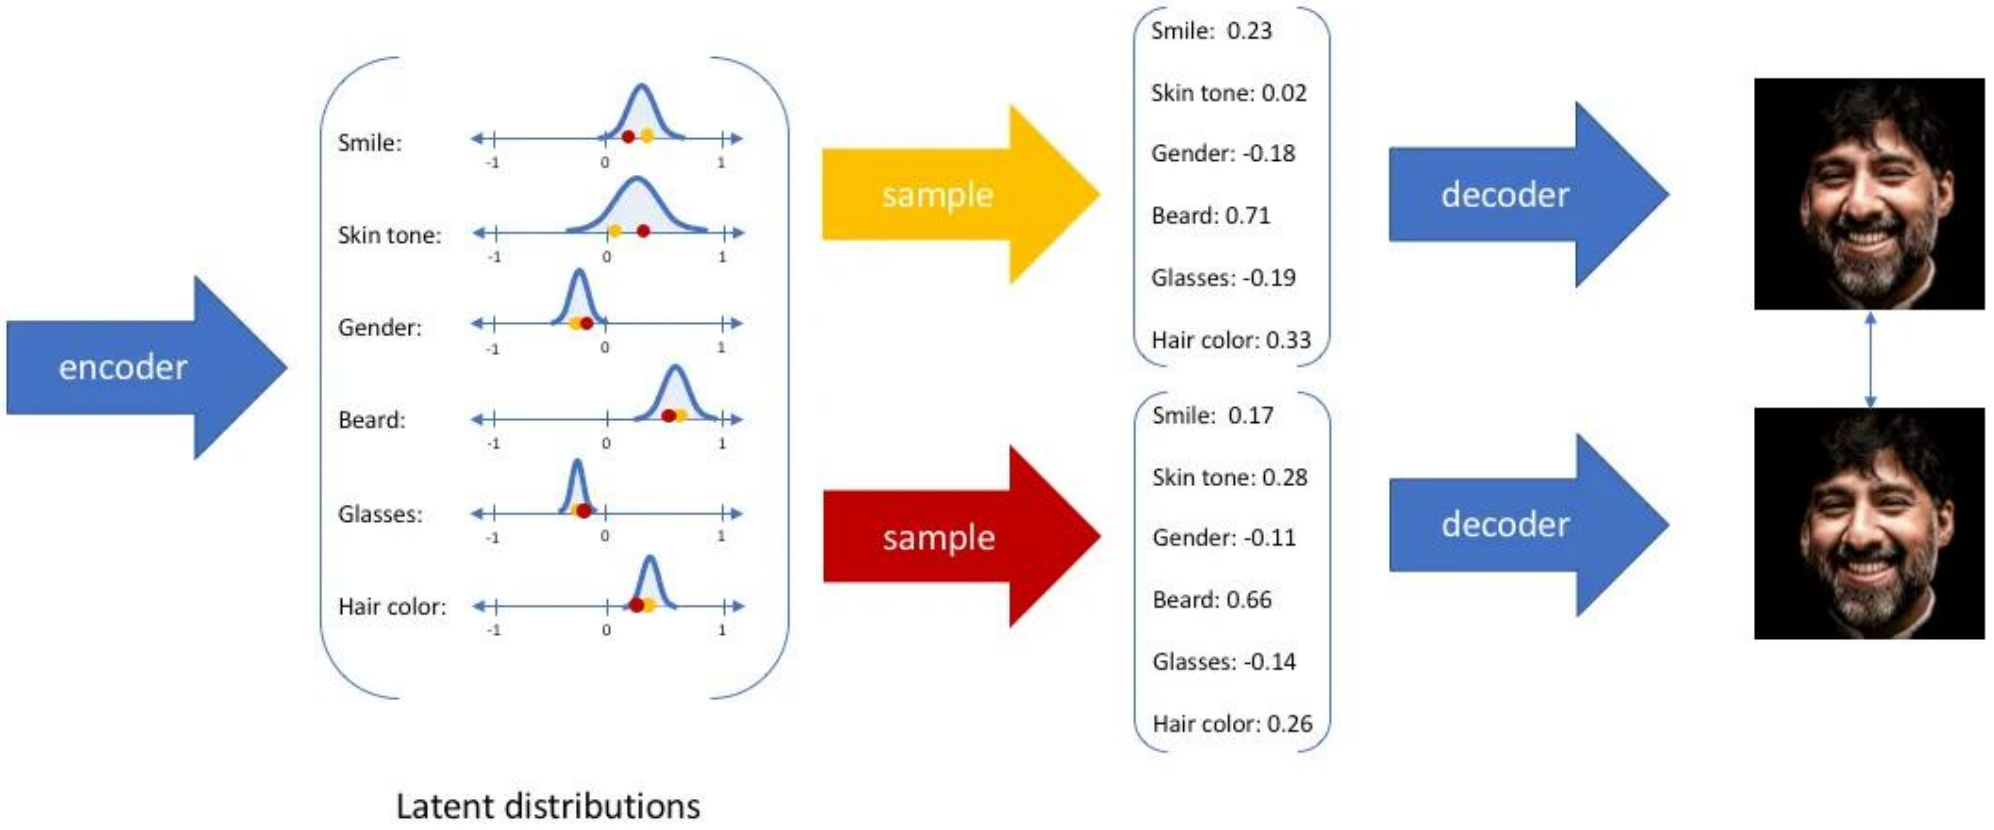
- VAEs **geram dados** e não apenas os codificam/comprimem.



https://blog.csdn.net/starwxd

Gerar dados com os VAE

Um VAE cria **representações latentes probabilísticas** a partir dos dados de treino e, ao amostrar esses vetores latentes e descodificá-los, gera **novos** dados **semelhantes** aos originais.



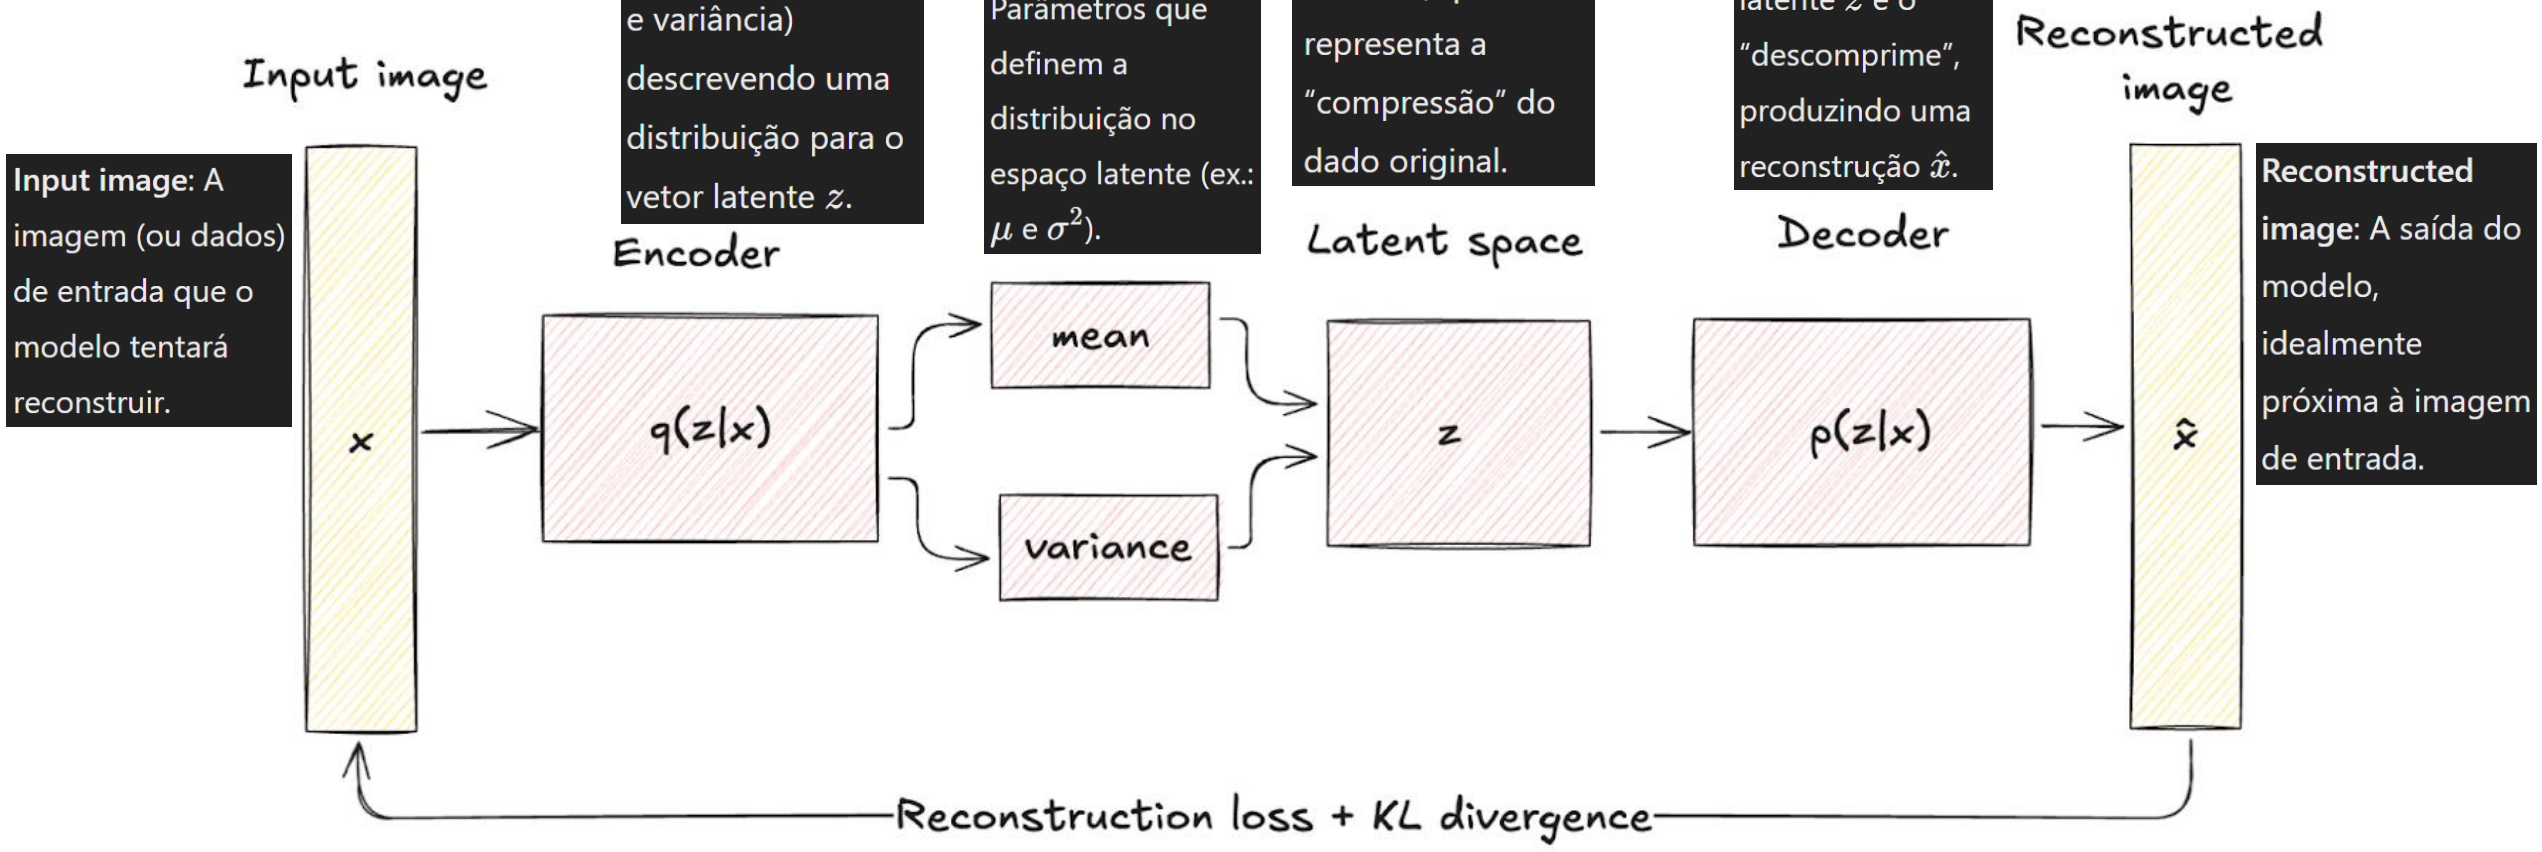
Treino de VAEs

Encoder (q(z|x)): Rede neural que, dada a imagem, gera parâmetros estatísticos (média e variância) descrevendo uma distribuição para o vetor latente z.

Mean & Variance: Parâmetros que definem a distribuição no espaço latente (ex.: μ e σ^2).

Latent space (z): Um vetor amostrado a partir da distribuição gerada pelo encoder, que representa a "compressão" do dado original.

Decoder (p(x|z)): Rede neural que recebe o vetor latente z e o "descomprime", produzindo uma reconstrução $\hat{x}$.



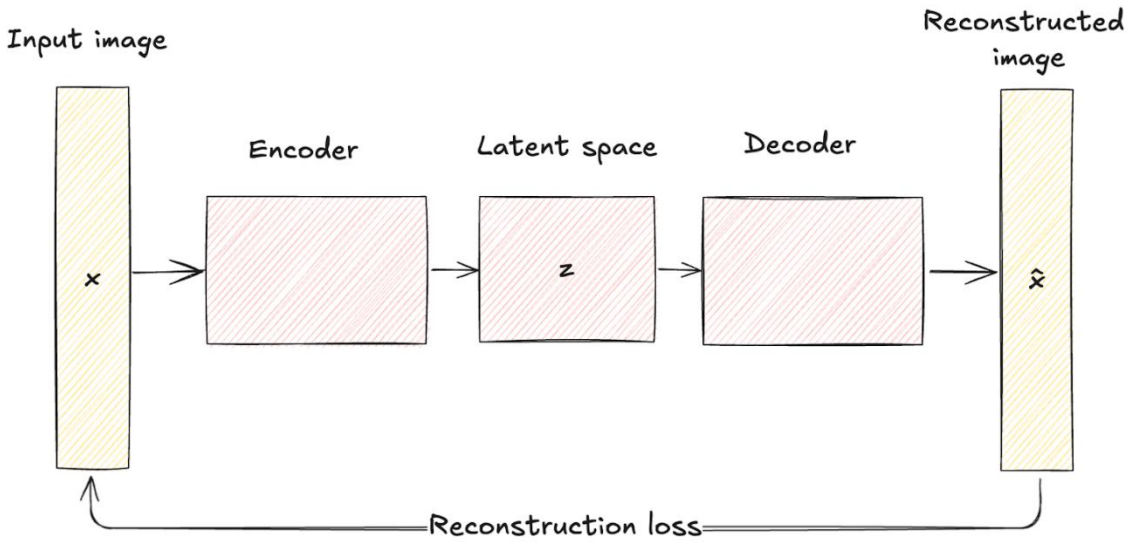
Input image: A imagem (ou dados) de entrada que o modelo tentará reconstruir.

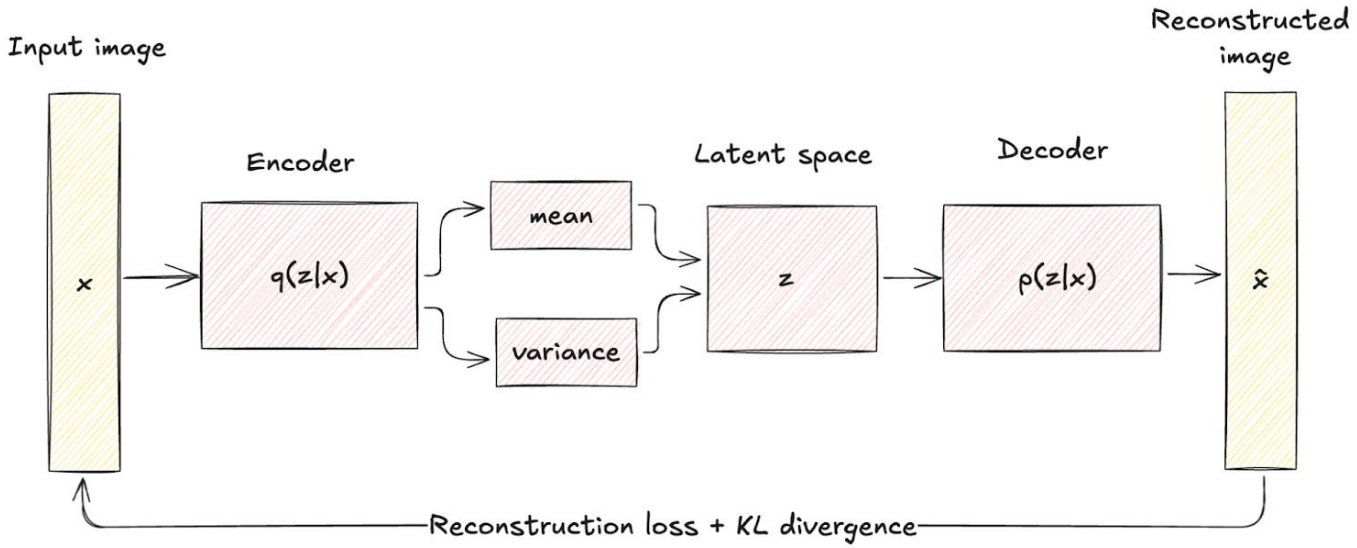
Reconstructed image: A saída do modelo, idealmente próxima à imagem de entrada.

um ßVAE (betaVAE) tem um fator beta para controlar a ênfase do KL

Loss (Reconstruction + KL Divergence): Função de custo que combina o erro de reconstrução (o quão diferente está $\hat{x}$ de x) e a divergência KL (que incentiva z a seguir uma distribuição pré-definida, normalmente $\mathcal{N}(0, I)$).

Treino de AEs vs Treino de VAEs

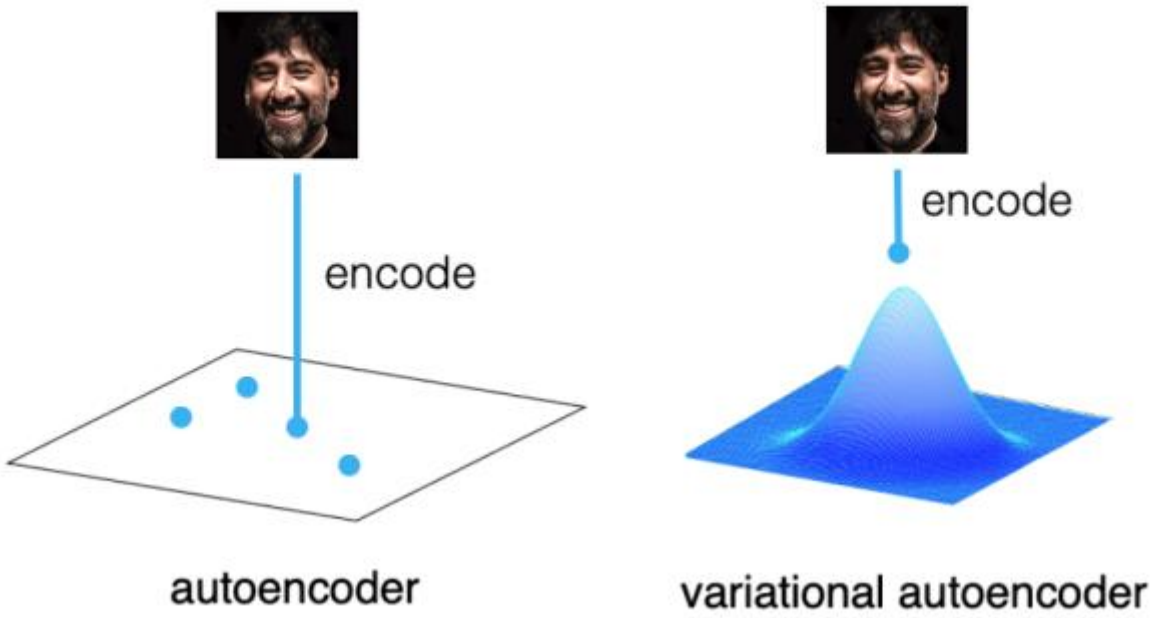




Espaço Latente dos Variational auto-encoder (VAE)

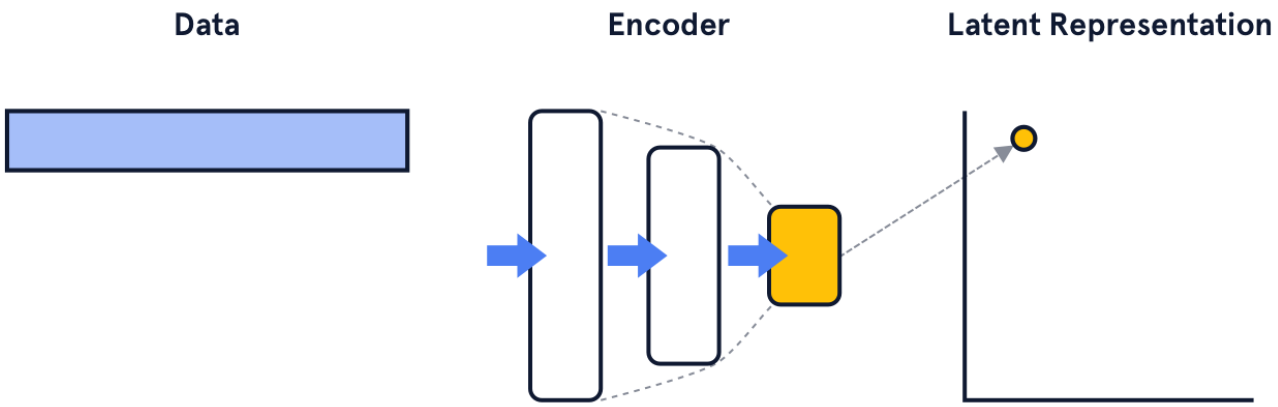
Os AEs aprendem **um espaço de vetores** discreto.

Os VAEs aprendem **um espaço de vetores** continuo e probabilístico.



Aprendizagem de representações.

A **Aprendizagem de Representações** extrai, a partir de dados brutos, características relevantes.



Ao capturar a distribuição dos dados, permite identificar outliers para isolar anomalias em áreas como deteção de fraudes, diagnóstico médico ou manutenção preditiva

Aplicações práticas.

1. Geração de Imagens
   - Criar novos exemplos realistas (rostos, objetos, etc.).
2. Compressão de Dados
   - Aprender codificações mais eficientes que métodos tradicionais.
3. Criação de Conteúdos Sintéticos
   - Áudio, texto ou dados multimodais para testes e experimentos.
4. Análise de Anomalias
   - Detetar desvios ao reconstruir padrões e comparar com o esperado.

Lab

- Lab 02 - Variational Autoencoders (VAEs)